선택적 특징 융합을 적용한 트랜스포머 기반 소형 객체 탐지

Transformer Based Small Object Detection with Selective Feature Fusion

Abstract : Small object detection in military border surveillance suffers from a significant bounding box precision gap when lightweight models resize high-resolution images (1920×1080) to their input resolution. RF-DETR, a state-of-the-art real-time detection transformer, achieves high recall but limited localization precision on our military border dataset, as 73% of annotated "large" objects (COCO[8] definition) become effectively small (shorter side 〈 32px) after resizing to 576×576. This makes the precision gap pervasive across all classes rather than confined to inherently small objects. To address this while preserving NAS-optimized decoder structure of RF-DETR, we apply two complementary techniques to the NAS-unmanaged pipeline gaps. First, Selective Cross-Attention leverages self-attention map of DINOv2 as a spatial prior to select only the top-25% small-object candidate CNN tokens for cross-attention injection into ViT features. Unlike prior CNN-ViT fusion approaches that indiscriminately merge all tokens, our selective strategy prevents background noise from diluting small-object features. Second, we replace GIoU with Normalized Wasserstein Distance (NWD) in the Hungarian matching loss — a stage where prior NWD applications have not been explored — stabilizing GT assignment for scale-sensitive objects at zero inference loss. The combined framework achieves mAP@50:95 of 0.906 with Person AP@75 of 0.713 (+4.0%) on the AIHub military border dataset(10 classes, 41,472 GT instances), while reducing total false positives by 38.8%. TensorRT FP16 benchmarks on NVIDIA AGX Orin 64GB confirm real-time deployment at 7.46ms (134 FPS) with SCA, representing only +7.0% latency overhead over RF-DETR-M (6.97ms, 143 FPS).

keywords : Small Object Detection, Detection Transformer, CNN-ViT Feature Fusion, Normalized Wasserstein Distance, Military Border Surveillance

1. 서 론

객체 탐지(Object Detection)는 영상 보안 감시 시스템(Video Surveillance System)에 있어 필수적으로 요구되는 기술이다. 특히 카메라 또는 EO-IR 카메라 영상 데이터를 활용하여 자동으로 객체를 탐지함으로써 효율적인 군 경계를 지원하는데 활용되고 있다. 군 경계 감시 체계는 광범위한 감시 영역에 대하여 사람, 조류, 무인항공기, 소형 선박 등의 다양한 객체를 신속하고 정확하게 탐지하는 것이 요구된다.

최근 딥러닝 객체 탐지 기술의 발전으로 고성능 GPU 또는 NPU를 탑재한 워크스테이션 또는 서버를 활용한 객체 탐지 시스템이 민간의 영상 보안 감시뿐만 아니라 군 경계에도 적용되고 있다. 또한, 엣지 컴퓨팅 환경에서 객체 탐지 시스템 구현을 위한 모델 경량화 및 최적화 연구가 활발히 진행되고 있다.

객체 탐지 기술은 CNN(Convolutional Neural Network) 계열과 트랜스포머(Transformer) 계열 모델이 제안되고 있다. CNN 계열에서는 YOLO 계열의 모델이 주로 활용되고 있다. 최근 트랜스포머를 기반으로 하는 객체 탐지 모델로 DETR(Detection Transformer)[1]이 제안되었고, 탐지 성능을 개선하여 Deformable DETR[2], DINO[3], Co-DETR[4] 모델이 제안되었다. 실시간 처리를 위하여 RT-DETR[5]와 RF-DETR[6]이 제안되어 실시간 객체 탐지에 있어 주목할 결과를 도출하였다. 특히 RF-DETR[6]은 NAS(Neural Architecture Search) 구조와 DINOv2 ViT(Vision Transformer)[7]를 결합하여 COCO[8] 데이터셋 벤치마크에서 우수한 성능을 보였다. RF-DETR은 객체 탐지에 있어 IoU 기준에 따른 성능 차이가 크다. 이는 모델이 객체의 위치는 파악하지만 바운딩 박스(bounding box)의 크기와 경계를 정밀하게 반영하지 못한 결과이다. 특히 소형 객체에 대해서 IoU 기준에 따른 현저한 차이가 있다.

본 논문에서는 효율적인 경계를 위하여 트랜스포머 기반의 소형 객체 탐지 모델을 제안한다. 제안하는 모델은 RF-DETR의 DINOv2 백본을 활용하고 CNN-ViT 융합[9] 및 선택적 교차 어텐션, 소형 객체 탐지에 적합한 손실 함수를 적용하는다. RF-DETR의 특정 블록이 소형 객체의 특징을 나타내는 것을 확인하고 이를 강조하는 선택적 교차 어텐션(SCA, Selective Cross-Attention)를 적용한다. 그리고 RF-DETR의 헝가리안 정합(Hungarian matching) 손실에서 GIoU를 대신하여 NWD(Normalized Wasserstein Distance)[10] 적용하는 손실 함수를 제안한다.

제안하는 소형 객체 탐지 학습과 성능 평가를 위하여 군 경계 실환경 데이터셋을 활용한다. GPU 워크스테이션과 온디바이스 AI 디바이스 상에서의 시험 및 성능 평가 결과 제안하는 객체 탐지 모델이 소형 객체 탐지 성능을 개선할 수 있음을 보인다.

2. 원거리 소형 객체 탐지

2.1. 트랜스포머 기반 객체 탐지

DETR[1]은 트랜스포머의 self-attention과 이분 매칭을 영상 데이터의 객체 탐지에 적용하여 CNN YOLO 계열 모델에서 주로 사용하는 앵커(Anchor)와 NMS(Non-Maximum Suppression) 없는 효율적인 모델이다. Deformable DETR[2]은 변형 가능한 어텐션으로 수렴 속도와 소형 객체 성능을 개선한다. DINO[3]은 대조적 디노이징과 앵커 초기화로 COCO 데이터셋에 대하여 우수한 탐지 성능을 보인다. Co-DETR[4]은 협업적 하이브리드 할당으로 학습 효율을 높이며, RT-DETR[5]은 하이브리드 인코더 설계로 DETR의 실시간 처리가능성을 제시한다. RF-DETR[6]은 NAS를 통해 디코더 구조, 쿼리 수, 입력 해상도 등을 자동 탐색하여 DINOv2[7] 백본과 결합한 실시간 객체 탐지를 수행한다.

2.2. 소형 객체 탐지와 NWD

Wang 등[10]은 bbox(Bounding Box)를 2D 정규분포(Gaussian distribution) 모델링하고 Wasserstein-2 거리를 계산하는 NWD를 제안한다. NWD는 IoU(Intersection over Union)이 극소형 객체에서 1~2화소(pixel) 오차에도 급변하는 문제를 완화하여 안정적인 거리 측정을 제공한다. Xu 등[11]은 NWD를 항공 영상 소형 객체 검출에 적용하여 유효성을 검증하였으며, Yang 등[12]은 NWD를 DETR 계열의 손실 함수에 적용하였다. 그러나 이들은 모두 헝가리안 정합(Hungarian matching) 이후의 비용(Cost or Loss) 단계에서만 NWD를 사용한다. 매칭 단계에서 잘못된 GT(Ground Truth) 할당이 이루어지면 이후 비용 함수를 아무리 정교하게 설계하더라도 학습 신호의 품질을 개선하기 어렵다. 본 연구는 매칭 비용에 NWD를 직접 도입하는 접근을 취한다. 한편, 드론

촬영 영상 환경에서의 소형 객체 탐지 벤치마크[13]도 유사한 스케일 문제를 보고하며, 본 연구의 도메인 분석과 일치하는 경향을 보인다.

2.3. CNN-ViT 특징 융합

ViT 백본의 고정 패치 크기(16×16)로 인한 소형 객체 표현 한계를 보완하기 위해, CNN 분기의 고해상도 특징을 ViT 특징에 융합하는 연구가 수행되었다. ViT-Adapter[9]는 CNN 분기의 전체 토큰을 ViT 특징에 cross-attention으로 융합한다. 그러나 이 무차별적 융합은 두 가지 구조적 한계를 갖는다. 첫째, 군 경계 데이터셋 기준 이미지 면적 대비 소형 객체 총 면적은 5% 미만이므로 CNN 토큰의 95% 이상이 배경 정보를 담고 있어 불필요한 연산이 발생한다. 둘째, 배경 영역의 CNN 특징이 ViT 특징에 무차별적으로 주입되면 소형 객체 특징이 희석된다. Caron 등[14]은 DINO의 자기지도 학습 특성상 self-attention이 전경 객체 영역을 자연스럽게 활성화함을 보이며, DINOv2[7]는 이 특성을 계승한다. 이러한 attention map은 선택적 토큰 선정의 사전 지식(prior)으로 활용될 수 있으나, CNN 토큰 선택에 적용한 연구는 탐구되지 않았다.

2.4. 소형 객체 탐지 설계 고려 사항

RF-DETR[6]의 NAS가 최적화한 컴포넌트(디코더 FFN 차원, 레이어와 쿼리 수, 입력 해상도, 어텐션 윈도잉)를 수정하면 NAS 탐색의 최적성이 훼손될 수 있다. 본 연구의 두 기법은 NAS가 관리하지 않는 파이프라인 간극, 즉 백본-프로젝터 사이(SCA)와 헝가리안 정합 비용만 적용하여 NAS 최적화 구조를 완전히 보존한다.

RF-DETR-M의 DINOv2 ViT-S/16 백본은 16×16px 고정 패치 단위로 이미지를 처리한다. 576×576 입력에서 36×36=1,296개 토큰을 생성하지만, 군 경계 데이터의 Person 객체(원본 약 35×55px)는 리사이즈 후 약 10.5×16.5px로 축소되어 약 0.7개 패치 면적으로만 표현된다. 이 극소 면적의 패치로는 객체의 경계를 정밀하게 표현할 수 없어 bbox 정밀도가 구조적으로 제한된다.

이러한 해상도 한계를 극복하기 위해 CNN 분기의 고해상도 특징을 ViT 특징에 보충하는 접근을 고려할 수 있다. 그러나 기존 ViT-Adapter[9]와 같이 CNN 전체 토큰을 무차별적으로 융합하면 배경 영역의 노이즈가 소형 객체의 특징을 희석시키는 부작용이 발생한다.

따라서 소형 객체가 존재할 가능성이 높은 영역만 선별하여 해당 토큰만 융합하는 선택적 전략이 필요하다.

3. 제안하는 소형 객체 탐지

제안하는 소형객체 탐지, SOD(Small Object Detection) 파이프라인은 Figure 1과 같다. SOD 파이프라인은 소형 객체 탐지 정확도를 개선하기 위하여 RF-DETR에 대하여 소형 객체 후보 추출(Small Object Heatmap), SCA(Selective Cross Attention)모듈, NWD(Normalized Wasserstein Distance) 모듈을 추가한 것이다.

소형 객체 후보 추출은 DINOv2 백본에서 출력된 특징맵을 CNN 분기(CNN Branch)와 클래스 어텐션 맵 모듈을 결합하여 소형 객체 히트맵을 추출한다. SCA는 소형 객체 히트맵의 상위 25% 토큰을 선택하여 소형 객체의 속성을 반영하는 특징을 강화하는 교차 어텐션 처리를 하고 소형 객체 속성이 강화된 특징맵 산출하여 NAS투영 모듈로 전달한다. NWD 모듈은 RF-DETR의 정합 비용 산출을 위한 GIoU를 대신하여 NWD를 적용하여 소형 객체 위치 정확도를 개선하도록 한다.

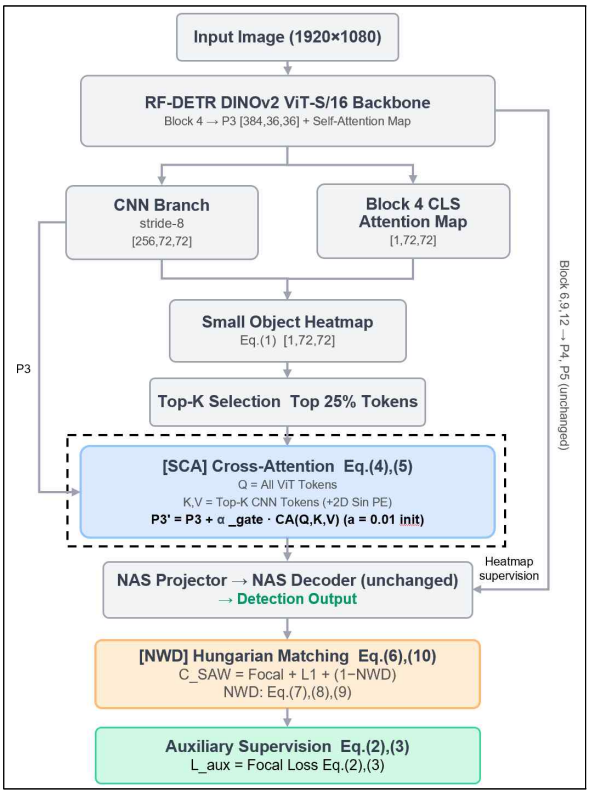

Figure 1. Pipeline of the proposed small object detection

3.1. 선택적 교차 어텐션

CNN 분기는 입력 영상에서 Conv3×3(stride 2) 3개 레이어와 Conv3×3(stride 1) 1개 레이어로 구성된다. 각 단계의 레이어를 거치면서 해상도 72×72로 작아지면서 특징이 정제된 [256, 72, 72] 크기의 특징맵(D_3)을 출력한다. 각 레이어의 정규화는 GroupNorm[15]을 사용하여 작은 배치(batch)에서도 안정적으로 동작한다.

CNN 분기에서 추출한 고해상도 특징 중 어느 영역을 ViT에 융합할지 결정하기 위해 소형 객체 히트맵 S를 생성한다. DINOv2 백본 블록 4의 특징은 소형 객체의 특징을 잘 포함하고 있다. 블록 4 클래스 어텐션 맵 생성 모듈은 DINOv2 블록 4의 클래스 토큰이 각 패치에 부여한 어텐션 가중치 맵(A)을 생성한다.

CNN 분기의 D_3 특징맵과 DINOv2 블록 4어텐션 가중치 맵, A를 결합한(concat) 후 1×1 Conv와 시그모이드(Sigmoid)를 적용하여 각 위치의 소형 객체 존재 가능성을 0~1 범위로 출력한다. 이 과정은 식 (1)과 같다.

$$S = \sigma(Conv_{1\times1}([D_3;\ A])) \quad \cdots\cdots (1)$$

여기서, S는 소형 객체 히트맵이고, D_3와 A는 각각 CNN 분기의 특징맵과 DINOv2 블록 4 어텐션 가중치 맵이다.

소형 객체 히트맵 S는 추론 시 Top-K 토큰 선택의 기준이 되므로, 학습 과정에서 S가 실제 소형 객체 위치를 정확히 반영하도록 직접 감독이 필요하다. 이를 위해 소형 GT bbox(area ≤ 1024) 중심에 가우시안 히트맵(Gaussian Heatmap)을 생성하고, S와의 차이를 Focal Loss[16]로 감독한다. 보조 감독 손실, L_{aux}는 식 (2)와 같다.

$$L_{aux} = -\frac{1}{N}\sum_{i=1}^{N}\alpha_i(1-p_i)^{\gamma}\log p_i \quad \cdots\cdots (2)$$

α_i, p_i 는 각각 클래스 가중치, t번째 위치에서 모델이 출력 예측 확률이다. γ 정상적인 검출의 비용 함수 반영을 억제하는 계수이다. N은 히트맵의 전체 위치 수이다. $\gamma = 2$, $\alpha_i = 0.25$로 설정한다. GT 히트맵은 각 소형 객체 GT bbox 중심에 가우시안 커널로 생성하며, 커널 $G(x,y)$은 식 (3)과 같이 정의한다.

$$G(x,y) = \exp(-E_x - E_y) \quad \cdots\cdots (3)$$

$E_x = (x-c_x)^2/2\sigma_x^2$, $E_y = (y-c_y)^2/2\sigma_y^2$ 이며, x와 y 는 히트맵의 가로, 세로 좌표이며, c_x, c_y는 소형 GT bbox(area 〈= 1024)의 중심 좌표 기준이다. $\sigma_x = w/6$, $\sigma_y = h/6$ 으로 설정한다.

히트맵 S가 생성되면 값이 높은 상위 25% 위치의 CNN 토큰만 선택하여 ViT 특징에 융합한다. 25%의 선택 비율은 평가 데이터셋의 소형 객체 면적 비율(전체 이미지 대비 약 5%)을 고려하되, 객체 주변 문맥 정보까지 포함하도록 여유를 둔 설정이다. 전체 토큰 대신 상위 25%만 사용함으로써 교차 어텐션의 연산량이 약 75% 감소하고, S 값이 낮은 배경 영역의 CNN 특징이 ViT 특징에 주입되지 않아 배경 잡음에 의한 소형 객체 특징 희석을 방지한다.

SCA(Selective Cross-Attention)는 CNN 분기, 소형 객체 히트맵, 선택적 교차 어텐션으로 구성된다. SCA 모듈의 상세 구조는 Figure 2와 같다.

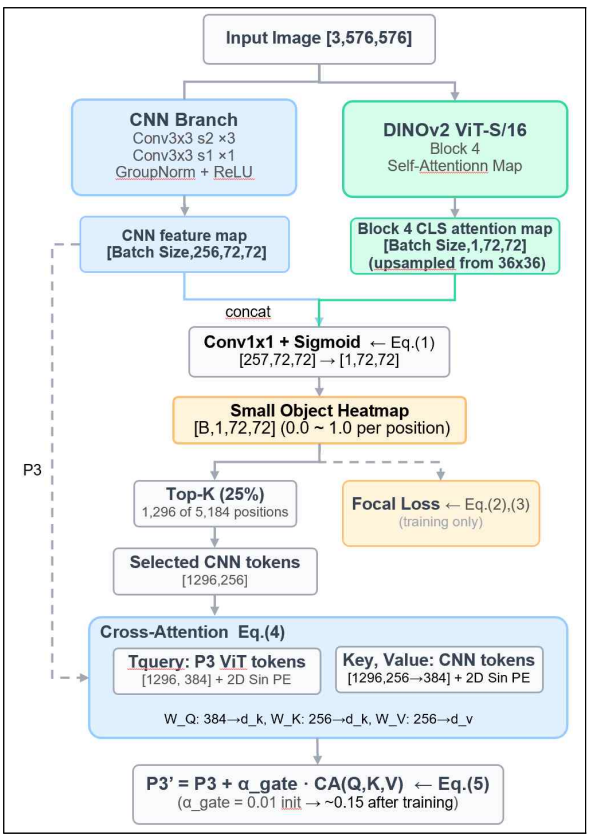

Figure 2. Architecture of the SCA module

선택된 CNN 토큰을 키(Key)와 값(Value)으로, ViT의 전체 1,296개 토큰을 쿼리(Query)로 하여

교차 어텐션을 수행한다. Q와 K에 각각 2D 삼각 위치 인코딩(sinusoidal position encoding, PE)을 추가하여 공간 정보를 보존한다. 교차 어텐션은 식 (4)와 (5)와 같이 스케일 내적 어텐션(Scaled Dot-Product Attention) 계산을 한다.

$$CA(Q,K,V) = softmax\left(\frac{QK^T}{\sqrt{d_k}}\right)V \cdots\cdots (4)$$

$$P_3' = P_3 + \alpha_{gate} \cdot CA(Q,K,V) \cdots\cdots (5)$$

P_3 는 DINOv2 백본의 블록 4의 특징이고, P_3'는 소형 객체의 속성을 강화한 특징맵이다. α_{gate} 는 게이팅 파라미터로써 0.01 초기화한다. $Q = P_3$, $K = V = TopK(D_3, S)$이다. SCA는 P_3 특징의 차원(384)을 변경하지 않으므로, 이후 NAS 프로젝터와 디코더에 대한 수정이 불필요하다.

3.2. 제안하는 소형 객체 탐지 모델의 손실 함수

DETR 계열 모델은 헝가리안 정합(Hungarian matching)을 통해 예측 쿼리와 GT를 일대일 배정하며, 정합 손실 함수(Loss function)에 반영한다. RF-DETR의 정합 손실은 식 (6)과 같이 구성된다.

$$C_{base} = \lambda_{cls} \cdot L_{focal} + \lambda_{L1} \cdot L_{L1} + \lambda_{giou} \cdot L_{GIoU} \cdots\cdots (6)$$

여기서 C_{base}는 예측 쿼리와 GT 간의 매칭 손실이다. L_{focal}은 Focal Loss[16] 기반의 분류 비용을 나타내고, L_{L1}은 정규화 좌표 기준의 L_1 위치 손실이고, L_{GIoU}는 GIoU 기반의 형태 유사도 비용을 나타낸다. λ_{cls} = 2, λ_{L1} = 5, λ_{giou} = 2로 각 항의 가중치이다.

GIoU 항은 객체 크기에 민감한 구조적 한계를 갖는다. IoU는 두 박스의 겹치는 면적을 합집합 면적으로 나누어 계산하므로, 동일한 화소 오차라도 객체가 작을수록 겹치는 면적의 비율 변화가 크게 발생한다. 소형 객체에서는 미세한 위치 오차가 IoU를 급격히 하락시키는 반면, 대형 객체에서는 동일한 오차가 IoU에 거의 영향을 주지 않는다. 평가 데이터셋에서는 리사이즈 후 대부분의 객체가 소수의 ViT 패치 크기로 축소되므로, 이 불안정성이 전체 클래스에 걸쳐 발생한다.

본 논문에서는 GIoU 대신 NWD를 적용한다. NWD는 bbox를 2D 가우시안 분포로 모델링하여 두 분포 간의 거리를 측정한다. bbox를 확률 분포로 변환하면 면적 비율이 아닌 분포 간 이동 거리로 유사도를 측정하게 되므로, 객체 크기에 따른 민감도 차이가 완화된다. 가우시안 분포의 평균과 공분산은 식 (7)과 (8)로 각각 정의한다.

$$\mu = (c_x, c_y) \cdots\cdots (7)$$

$$\Sigma = diag(w^2/4, h^2/4) \cdots\cdots (8)$$

μ는 가우시안 분포의 평균으로, bbox의 중심 좌표 (c_x, c_y)를 대입한다. Σ는 가우시안 분포의 공분산 행렬로, w는 박스의 너비, h는 높이를 나타낸다.

$$W_2^2 = ||\mu_A - \mu_B||^2 + ||\sigma_A - \sigma_B||^2 \cdots\cdots (9)$$

W_2는 두 가우시안 분포 간의 Wasserstein 거리이다. μ_A와 μ_B는 각각 예측 bbox와 GT의 bbox를 모델링한 가우시안 분포의 평균을 나타내고, σ_A와 σ_B는 각각의 표준편차 벡터이다. 여기서 표준편차 벡터는 σ=($w/2$, $h/2$)이다. 첫째 항은 두 분포의 평균 간 거리를, 둘째 항은 두 분포의 형태 간 차이를 측정한다.

Wasserstein 거리를 0~1 범위의 유사도로 정규화하기 위해 식 (10)의 지수 함수를 적용한다.

$$NWD(A,B) = \exp\left(-\frac{W_2}{C}\right) \cdots\cdots (10)$$

W_2는 식 (9)에서 산출한 W_2^2에 제곱근을 취한 값이다. C는 정규화 상수로 0.5이며 0에서 1 범위의 정규화 좌표 기준으로 설정한다. NWD가 1이면 두 분포가 완전히 일치하고, 0에 가까울수록 상이하다.

16×16 화소 객체에서 2 화소의 양방향 이동이 발생하면 IoU는 0.62까지 급락하는 반면, NWD는 0.78을 유지하여 26% 높은 유사도를 보존한다. 96×96 화소 객체에서는 동일한 2 화소 이동에도 IoU가 0.96, NWD가 0.99로 두 지표 모두 안정적이다. 즉 NWD는 소형 객체에서의 급격한 유사도 하락을 완화하면서 대형 객체에서의 안정성은 그대로 유지한다. Figure 3은 16×16 객체에서의 IoU와 NWD 응답 차이를 비교한 것이다. 식 (6)의 GIoU 항을 NWD로 대체한 매칭 비용은 식 (11)과 같이 정의한다.

$$C_{NWD} = \lambda_{cls} \cdot L_{focal} + \lambda_{L1} \cdot L_{L1} + \lambda_{nwd} \cdot (1 - NWD) \quad (11)$$

C_{NWD}는 NWD를 적용한 정합 비용을 나타낸다. (1 - NWD)는 식 (10)의 유사도를 비용으로 변환한 것으로, 두 분포가 유사할수록 비용이 낮아진다. λ_{nwd} = 2, λ_{giou} = 0으로 설정하여 식 (6)의 GIoU를 NWD로 대체하며, λ_{cls} = 2와 λ_{L1} = 5는 식 (6)과 동일하게 유지한다. Hungarian matching은 학습 시에만 동작하므로 추론 비용은 0%이며 추가 파라미터도 0개이다.

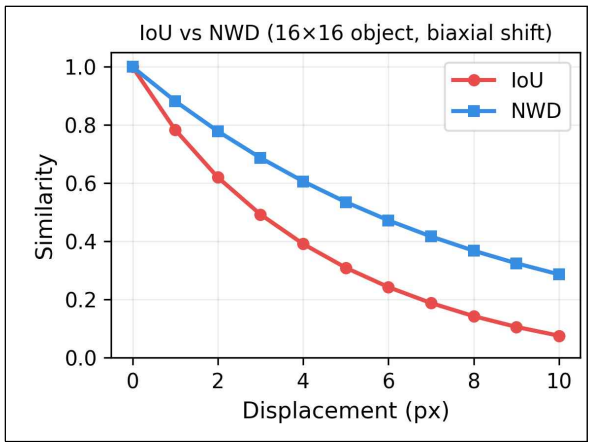

Figure 3. IoU vs NWD response comparison

4. 시뮬레이션 결과 및 검토

4.1. 시험 환경

AI-Hub 군 경계 작전 환경 실데이터(ID 71858)[17]와 군 경계 작전 합성데이터(ID 71856)[18]를 병합한 데이터셋을 활용하여 제안하는 객체 탐지 모델의 성능을 검증한다.

군 경계 작전 데이터셋은 10개 클래스(Fishing_Boat, Merchant_Ship, Warship, Person, Bird, Fixed_Wing, Rotary_Wing, UAV, Leaflet, Trash_Bomb)로 구성되며, 시험(test)를 위한 영상과 bbox GT는 각각 20,172건, 41,472건 이다.

제안하는 객체 탐지 모델에 대하여 CNN계열의 YOLOv11[19], YOLOv12[20](N/S/M/L)와 트랜스포머 기반 RF-DETR을 비교 분석한다. RF-DETR-Base의 입력 데이터의 해상도는 576×576이다. 모델 학습을 위해서 AdamW 최적화 알고리즘 적용하고 학습율은 1e-4, 배치크기는 16, 100 세대(epoch)으로 학습한다.

4.2. 성능 시험 결과 및 분석

학습과 시험은 RTX 5090 32GB에서 수행한다. 처리속도에 대한 비교는 RF-DETR-Base와 제안하는 모델의 성능 평가 및 비교 분석한다. 성능 평가는 mAP를 적용하고 시험 결과는 Table 1과 같다. mAP@50:95와 Person AP@50:95를 비교한 결과이다. mAP@50:95는 데이터셋의 모든 클래스를 비교한 결과이고 Person AP@50:95는 소형 객체인 Person 객체 탐지 결과이다.

YOLOv11과 YOLOv12의 mAP@50:95는 0.825~0.874 범위이고, RF-DETR-Base는 0.902로 3~8% 우수하다. 특히, 소형 객체인 Person 클래스에서 YOLOv11과 YOLOv12가 0.29~0.389 범위이지만, RF-DETR-Base는 0.673으로 상대적으로 성능이 우수하다. CNN계열의 YOLO 모델에 비해서 트랜스포머 기반의 객체 탐지 성능이 대체로 우수함으로 확인할 수 있다.

특히, Area Attention[20]을 적용한 YOLOv12가 동일 스케일의 YOLOv11 대비 동등하거나 오히려 낮은 성능을 보인다는 것이다. YOLOv12의 국소영역 어텐션이 성능 평가 대상 데이터셋과 같이 소형 객체가 많은 데이터셋에 대해서는 성능이 개선되지 않음을 확인할 수 있다. 반면 RF-DETR의 DINOv2 ViT 백본은 전역 self-attention을 통해 패치 수준의 소형 객체에 대하여 상대적으로 우수한 탐지 결과를 보인다.

제안하는 SOD-SCA 그리고 SOD-SCA+NWD의 mAP@50:95 즉 모든 클래스에 대한 객체 탐지에 있어 각각 0.904, 0.906으로 RF-DETR-Base 대비 다소 성능이 개선된다. 소형 객체에 대한 탐지 성능, 즉 Person AP@50:95도 각각 0.704, 0.710으로 성능이 개선됨을 확인할 수 있다.

Figure 4는 평가 데이터셋의 10개 클래스에 대한 오탐지(FP, False Positive)의 원인을 중복 탐지(FP_duplicate), 배경 오탐지(FP_background), 그리고 위치 오탐지(FP_localization)으로 분류한 결과이다. 중복 탐지는 하나의 객체에 대하여 중복 탐지하는 것이고, 배경 오탐지는 배경을 객체로 탐지하는 것이다. 위치 오탐지는 실제 객체 근처에서 탐지하였으나, bbox의 위치가 부정확한 것으로 IoU가 0.5 미만인 것을 나타낸다.

RF-DETR-Base의 오탐지는 121건이고, SOD-SCA+NWD는 74로 38.8% 감소하였으며, FP_background, FP_localization 그리고 FP_duplication은 각각 85에서 48로,

FP_localization은 34에서 26으로 감소하고, FP_duplicate는 2에서 0으로 제거된다.

Model	mAP @50:95	Person AP@50:95
YOLOv11-N	0.837	0.290
YOLOv11-S	0.868	0.389
YOLOv11-M	0.870	0.374
YOLOv11-L	0.874	0.380
YOLOv12-N	0.825	0.215
YOLOv12-S	0.854	0.301
YOLOv12-M	0.867	0.370
YOLOv12-L	0.870	0.369
RF-DETR-Base	0.902	0.673
SOD-SCA	**0.904**	**0.704**
SOD-SCA+NWD	**0.906**	**0.713**

Table 1. Performance comparison on military border dataset

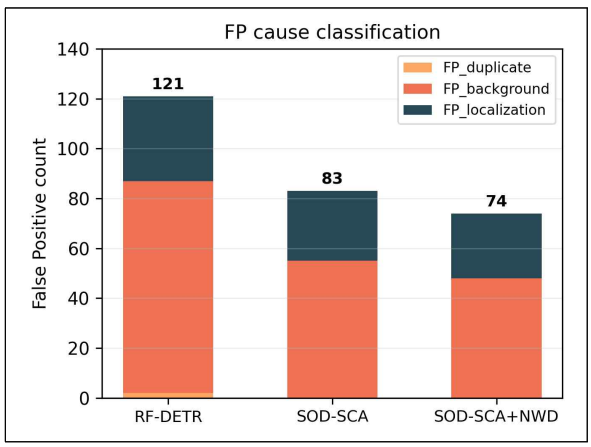

Figure 4. FP cause classification by experiment configuration

Figure 5은 RF-DETR-Base 모델이 탐지하지 못한 Person 객체를 SOD-SCA가 탐지한 결과로 제안하는 SOD 파이프라인이 소형 객체 탐지 성능을 개선할 수 있음을 보인다. SOD-SCA의 stride-8 CNN 분기가 ViT 패치 해상도로는 포착하지 못하는 소형 객체, Person 클래스 객체의 공간적 특징을 보완하여 검출기의 전경과 배경 판별력을 개선한 결과이다.

4.3. 온디바이스 AI 분석

본 논문에서는 제안하는 객체 탐지 모델을 온디바이스 AI 환경에서 탐지 성능과 처리 속도를 비교 분석한다. NVIDIA Jetson AGX Orin 64GB에서

Figure 5. Person $\mu = (c_x, c_y)$ detection results of RF-DETR-Base(left) and SOD-SCA(right)

TensorRT FP16 기준으로 성능과 처리 속도를 비교한다.

처리 속도와 탐지 성능을 비교한 결과는 Table 2에 나타낸다. RF-DETR-Base은 1 프레임 처리시간 6.97ms로 프레임율(frame rate)은 143 FPS이며, SOD-SCA+NWD는 각각 7.46ms, 134FPS 로 동등한 실시간 처리를 한다.

Model	TensorRT FP16(ms)	FPS
RF-DETR-Base	6.97	143.3
SOD-SCA+NWD	7.46	134.0

Table 2. AGX Orin TensorRT FP16 deployment analysis

5. 결론

본 연구는 군 경계 감시 엣지 환경에서 RF-DETR 모델의 소형 객체 bbox 정밀도를 개선하기 위한 객체 탐지 모델을 제안한다. 제안하는 소형 객체 탐지 모델은 SCA와 NWD를 적용한다.
SCA는 DINOv2의 self-attention map을 사전 지식으로 활용하여 경량 CNN 분기의 상위 25% 토큰만 선택적으로 ViT 특징에 교차 어텐션으로 융합한다.
군 경계 실환경 및 합성 데이터를 활용하여 학습 및 시험을 통하여 탐지 성능과 처리 속도를 비교 분석한 결과 제안하는 소형 객체 탐지에 효율적임을 확인할 수 있다. SOD-SCA+NWD는 mAP@50:95 0.906, Person AP@50:95 0.713(+4.0%)의 성능을 보이고, 전체 FP를 121건에서 74건으로 38.8% 감소시킨다. AGX Orin 64GB에서 TensorRT FP16 기준 SOD-SCA+NWD는 7.46ms(134 FPS)로 RF-DETR와 유사한 처리속도를 보인다.

참고문헌

1. Carion, N., Massa, F., Synnaeve, G., Usunier, N., Kirillov, A., & Zagoruyko, S. (2020). End-to-end object detection with transformers. *European Conference on Computer Vision*, 213-229. https://doi.org/10.1007/978-3-030-58452-8_13
2. Zhu, X., Su, W., Lu, L., Li, B., Wang, X., & Dai, J. (2021). Deformable DETR: Deformable transformers for end-to-end object detection. *International Conference on Learning Representations*. https://arxiv.org/abs/2010.04159
3. Zhang, H., Li, F., Liu, S., Zhang, L., Su, H., Zhu, J., Ni, L., & Shum, H. (2023). DINO: DETR with improved denoising anchor boxes for end-to-end object detection. *International Conference on Learning Representations*. https://arxiv.org/abs/2203.03605
4. Zong, Z., Song, G., & Liu, Y. (2023). DETRs with collaborative hybrid assignments training. *IEEE/CVF International Conference on Computer Vision*, 6748-6758. https://doi.org/10.1109/ICCV51070.2023.00621
5. Zhao, Y., Lv, W., Xu, S., Wei, J., Wang, G., Dang, Q., Liu, Y., & Chen, J. (2024). DETRs beat YOLOs on real-time object detection. *IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 16965-16974. https://doi.org/10.1109/CVPR52733.2024.01605
6. Robinson, P., Nogueira, K., & Stojanov, S. (2025). RF-DETR: Real-time detection transformer. *arXiv preprint arXiv:2501.00320*. https://arxiv.org/abs/2501.00320
7. Oquab, M., Darcet, T., Moutakanni, T., Vo, H., Szafraniec, M., Khalidov, V., ... & Bojanowski, P. (2024). DINOv2: Learning robust visual features without supervision. *Transactions on Machine Learning Research*. https://arxiv.org/abs/2304.07193
8. Lin, T., Maire, M., Belongie, S., Hays, J., Perona, P., Ramanan, D., Dollár, P., & Zitnick, C. (2014). Microsoft COCO: Common objects in context. *European Conference on Computer Vision*, 740-755. https://doi.org/10.1007/978-3-319-10602-1_48
9. Chen, Z., Duan, Y., Wang, W., He, J., Lu, T., Dai, J., & Qiao, Y. (2023). Vision transformer adapter for dense predictions. *International Conference on Learning Representations*. https://arxiv.org/abs/2205.08534
10. Wang, J., Xu, C., Yang, W., & Yu, L. (2022). A normalized Gaussian Wasserstein distance for tiny object detection. *IEEE Transactions on Geoscience and Remote Sensing*, 60, 1-11. https://doi.org/10.1109/TGRS.2021.3130365
11. Xu, C., Wang, J., Yang, W., Yu, H., Yu, L., & Xia, G. (2023). Detecting tiny objects in aerial images: A normalized Wasserstein distance and a new benchmark. *ISPRS Journal of Photogrammetry and Remote Sensing, 190*, 79-93. https://doi.org/10.1016/j.isprsjprs.2022.06.002
12. Yang, F., Li, Q., & Zhang, X. (2024). NWD-DETR: Normalized Wasserstein distance based DETR for tiny object detection. *IEEE Signal Processing Letters, 31*, 1034-1038. https://doi.org/10.1109/LSP.2024.3381178
13. Zhu, P., Wen, L., Du, D., Bian, X., Fan, H., Hu, Q., & Ling, H. (2021). Detection and tracking meet drones challenge. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 44(11), 7380-7399. https://doi.org/10.1109/TPAMI.2021.3119563
14. Caron, M., Touvron, H., Misra, I., Jégou, H., Mairal, J., Bojanowski, P., & Joulin, A. (2021). Emerging properties in self-supervised vision transformers. *IEEE/CVF International Conference on Computer Vision*, 9650-9660. https://doi.org/10.1109/ICCV48922.2021.00951
15. Wu, Y., & He, K. (2018). Group normalization. *European Conference on Computer Vision*, 3-19. https://doi.org/10.1007/978-3-030-01261-8_1
16. Lin, T., Goyal, P., Girshick, R., He, K., & Dollár, P. (2017). Focal loss for dense object detection. *IEEE/CVF International Conference on Computer Vision*, 2980-2988. https://doi.org/10.1109/ICCV.2017.324
17. AI Hub. (2024). *Military border operation environment recognition dataset (ID 71858)*. https://aihub.or.kr/aihubdata/data/view.do?dataSetSn=

71858

18. AI Hub. (2024). *Military border operation environment synthetic dataset (ID 71856)*. https://aihub.or.kr/aihubdata/data/view.do?dataSetSn=71856

19. Khanam, R., & Hussain, M. (2024). YOLOv11: An overview of the key architectural enhancements. *arXiv preprint arXiv:2410.17725*. https://arxiv.org/abs/2410.17725

20. Tian, Y., Ye, Q., & Doermann, D. (2025). YOLOv12: Attention-centric real-time object detectors. *arXiv preprint arXiv:2502.12524*. https://arxiv.org/abs/2502.12524

부 록

본 논문 원고 작성 과정에서 생성형 인공지능 Anthropic Claude(claude.ai)를 사용하여 문장 교정, 영문 초록 작성 및 논문 내 플로우차트 이미지 생성 보조 도구로 활용하였으며, 실험 설계, 데이터 수집 및 분석, 결과 해석은 저자가 직접 수행하였다.